

CardioIA — Fase 4 — Relatório Parte 1 (Pré-processamento)

Disciplina / projeto: CardioIA — Assistente Cardiológico Virtual (Visão Computacional)

Escopo: Seleção do dataset, definição da tarefa de classificação, pipeline de pré-processamento e organização dos conjuntos treino / validação / teste

Referências no repositório: `notebooks/fase4_parte1_preprocessamento.ipynb`, Google Drive `dataset_cardio/`

Integrantes: Diogo Rebello, Vera Chaves

Data: junho/2026

1. Objetivo deste relatório

Documentar as **escolhas técnicas e clínicas** da Parte 1 da Fase 4, conforme o enunciado FIAP: seleção de dataset público de imagens médicas, pré-processamento (redimensionamento, normalização, conversão de formato), criação dos splits e justificativa de cada etapa do pipeline implementado no Google Colab.

2. Dataset escolhido e continuidade com a Fase 1

2.1 Por que o CAMUS?

Utilizamos o dataset **CAMUS** (*Cardiac Acquisitions for Multi-structure Ultrasound Segmentation*), o mesmo ecocardiograma documentado na **Fase 1 — Parte 3 (Dados Visuais)** do CardioIA. Trata-se de imagens **públicas, anonimizadas** de ultrassom cardíaco 2D, alinhadas ao domínio cardiologico do projeto e ao requisito do enunciado de trabalhar com **imagens médicas simuladas/reaís de fonte aberta**.

Aspecto	Detalhe
Origem	CAMUS (versão Kaggle / exportação Fase 1)
Modalidade	Ecocardiografia (ultrassom cardíaco)
Volume	900 pares imagem + máscara
Formato	PNG, 384×384 pixels (original)
Armazenamento	Google Drive — <code>dataset_cardio/frames/</code> e <code>dataset_cardio/masks/</code>
Links Fase 1	Google Drive · Kaggle

Justificativa de continuidade: reutilizar o CAMUS evita trocar de domínio clínico entre fases, mantém coerência narrativa do CardioIA (dados visuais cardíacos desde a Fase 1) e aproveita o acervo já validado pela equipe. A versão no Drive foi organizada espelhando o Kaggle: pastas separadas `frames/` (imagens) e `masks/` (anotações expert de segmentação).

2.2 Por que não commitamos as imagens no Git?

Seguindo a governança do repositório, ~900 PNGs permanecem no **Google Drive**; o Git versiona apenas o notebook, este relatório e os **CSVs de índice** gerados pelo pipeline (caminhos apontando para o Drive).

3. Definição da tarefa de classificação

O enunciado da Fase 4 exige **classificar imagens médicas** com CNN, sem especificar quais classes. Avaliamos alternativas:

Alternativa	Problema
2CH vs 4CH (vista apical)	O export Kaggle/Drive usa <code>frame_XXXX.png</code> sem metadado de vista no nome; inferir por ordem seria frágil e difícil de validar.
NIH Chest X-rays	Atende o enunciado, mas quebra a continuidade com a Fase 1 (raio-X torácico ≠ ecocardiograma).
Estrutura predominante (escolhida)	As máscaras trazem anotações expert com três regiões (pixels 253, 254, 255). O rótulo é objetivo e reproduzível .

3.1 Tarefa adotada

Classificar, a partir somente da imagem do ecocardiograma, qual estrutura cardíaca segmentada é predominante na região anotada.

- Entrada do modelo (Parte 2):** apenas `frames/frame_XXXX.png`
- Geração de rótulos (Parte 1):** para cada par `frame_XXXX` ↔ `mask_XXXX`, calculamos qual valor entre **253, 254 e 255** ocupa **maior área** na máscara (excluindo fundo 0)
- Classes:** `estrutura_253`, `estrutura_254`, `estrutura_255`
- Modo alternativo no notebook:** classificação binária (`MODO_BINARIO = True`) — predominância 254 vs demais; não utilizado nesta execução

Justificativa clínica e pedagógica: o CAMUS foi criado para segmentação de estruturas cardíacas (cavidade ventricular, miocárdio, átrio esquerdo). Usar as máscaras como **fonte de verdade para rótulos** aproxima um cenário real em que anotações expert alimentam modelos de apoio — com a ressalva de que, na inferência, o protótipo **não** recebe a máscara (simulação de laudo assistido só com a imagem).

Governança: dados anonimizados; protótipo **educacional** — não substitui diagnóstico médico nem laudo oficial.

4. Pipeline de pré-processamento

```
Google Drive (dataset_cardio/)
|
├── frames/ → pareamento por índice → masks/
|
|           |
|           ▼
|           rótulo = pixel predominante (253|254|255)
|           |
|           ▼
|           índice CSV (900 linhas)
|
|           ▼
|           redimensionar 224×224
|           conversão RGB
|           normalização [0, 1]
|           |
|           ▼
|           split estratificado 70% / 15% / 15%
|           |
|           ▼
|           camus_indice_imagens.csv
|           camus_splits.csv
|           camus_preprocess_config.json
```

4.1 Redimensionamento (224 × 224)

Escolha: `IMG_SIZE = (224, 224)`.

Justificativa: dimensão padrão dos modelos **VGG16** e **ResNet50** (transfer learning na Parte 2), reduz custo computacional no Colab e uniformiza entradas de tamanhos ligeiramente variáveis. Interpolação `INTER_AREA` (OpenCV) preserva melhor bordas em downscale.

4.2 Conversão de formato (RGB)

Imagens originais em escala de cinza foram convertidas para **RGB (3 canais)** com `PIL.convert("RGB")`.

Justificativa: redes pré-treinadas em ImageNet esperam 3 canais; duplicar o canal cinza evita erro de shape na Parte 2 sem alterar o conteúdo visual.

4.3 Normalização ([0, 1])

Pixels divididos por 255 → `float32` no intervalo `[0, 1]`.

Justificativa: estabiliza gradientes na CNN simples; na Parte 2 aplicaremos normalização ImageNet adicional apenas no ramo de transfer learning, documentado no notebook correspondente.

4.4 Augmentação de dados

Não aplicada nesta Parte 1.

Justificativa: priorizamos pipeline reprodutível e baseline limpa para comparar CNN do zero vs transfer learning na Parte 2. Com classes desbalanceadas, augmentação agressiva poderia distorcer ainda mais a classe minoritária; se necessário, será avaliada na Parte 2 com validação cruzada.

5. Organização dos conjuntos (splits)

Parâmetro	Valor	Justificativa
Proporção	70% treino / 15% validação / 15% teste	Padrão em ML; teste reservado para avaliação final na Parte 2
Estratificação	Por classe (rótulo)	Mantém proporção das classes em cada split apesar do desbalanceamento
Seed	42	Reprodutibilidade entre execuções e integrantes
Vazamento	Verificado	Cada caminho_frame pertence a um único split

5.1 Resultados obtidos (execução Colab)

Métrica	Valor
Pares frame/máscara	900
Treino	630
Validação	135
Teste	135

Distribuição global das classes:

Classe	Aprox. quantidade	Observação
estrutura_254	~621	Classe majoritária
estrutura_255	~254	Classe intermediária
estrutura_253	~25	Classe minoritária — desbalanceamento

A estratificação garante representação mínima de cada classe nos três splits; a classe estrutura_253 terá poucos exemplos no teste (~4), o que limitará a confiança estatística para essa categoria — **limitação documentada** para o relatório da Parte 2.

6. Artefatos gerados

Salvos em `Meu Drive/dataset_cardio/`:

Arquivo	Conteúdo
<code>camus_indice_imagens.csv</code>	Índice completo: caminhos, máscaras, classe, rótulo numérico
<code>camus_splits.csv</code>	Índice + coluna <code>split</code> (treino / validacao / teste) — entrada da Parte 2
<code>camus_preprocess_config.json</code>	Metadados do pipeline (tamanho, classes, seed, caminhos)

Notebook: `notebooks/fase4_parte1_preprocessamento.ipynb` (Google Colab, execução de ponta a ponta validada).

7. Limitações e considerações éticas

- Desbalanceamento de classes** — modelos podem favorecer `estrutura_254`; métricas por classe (precisão, recall, F1) serão essenciais na Parte 2.
- Rótulos derivados de máscaras** — correto para treino; na vida real não haveria máscara na inferência; o protótipo deixa explícito o caráter **simulado/educacional**.
- LGPD e privacidade** — CAMUS é público e anonimizado; em produção seriam necessários consentimento, finalidade e controle de acesso.
- Viés** — dataset de um centro/equipamento; generalização limitada a outras populações ou aparelhos.
- Não substitui cardiologista** — classificação de região segmentada é exercício acadêmico de visão computacional, não laudo clínico.

8. Conclusão (Parte 1)

A Parte 1 do CardioIA — Fase 4 cumpre o escopo do enunciado: **dataset público de imagens médicas (CAMUS)**, pipeline de **pré-processamento** documentado, **splits** treino/validação/teste estratificados e artefatos persistidos para a Parte 2. A escolha de **reutilizar o CAMUS da Fase 1** garante continuidade do projeto; a tarefa de **classificação da estrutura predominante**, com rótulos extraídos das **máscaras expert**, evita inferências frágeis (como 2CH/4CH sem metadado) e mantém fundamentação clínica ligada à segmentação cardíaca.

Próximo passo concluído: Parte 2 — ver `relatorio_fase4_parte2.pdf`.

9. Evidências (checklist da entrega — Parte 1)

- ✓ Notebook Colab: `notebooks/fase4_parte1_preprocessamento.ipynb`

- ☒ Relatório Parte 1: `docs/relatorio_fase4_parte1.pdf`
- ☒ Dataset no Drive: `dataset_cardio/frames/` + `dataset_cardio/masks/`
- ☒ CSVs no Drive: `camus_indice_imagens.csv`, `camus_splits.csv`, `camus_preprocess_config.json`
- ☒ Prints do Colab: distribuição de classes, amostras frame/máscara, tabela de splits