

# CardioIA — Fase 4 — Relatório Parte 2 (CNN, Transfer Learning e Protótipo)

**Disciplina / projeto:** CardioIA — Assistente Cardiológico Virtual (Visão Computacional)  
**Escopo:** Treinamento e avaliação de CNN simples e transfer learning (VGG16), métricas de classificação e protótipo de apresentação com interpretação assistida simulada  
**Referências no repositório:** `notebooks/fase4_parte2_cnn_classificacao.ipynb`, `notebooks/fase4_parte1_preprocessamento.ipynb`, Google Drive `dataset_cardio/`  
**Integrantes:** Diogo Rebello, Vera Chaves  
**Data:** junho/2026

## 1. Objetivo deste relatório

Documentar a **Parte 2** da Fase 4 conforme o enunciado FIAP: implementação de rede CNN para classificar imagens pré-processadas, comparação entre **CNN do zero** e **transfer learning**, avaliação com métricas de aula (acurácia, matriz de confusão, precisão, recall, F1-score) e descrição do **protótipo** do Assistente Cardiológico Virtual, incluindo interpretação em linguagem acessível e **avisos médicos obrigatórios**.

## 2. Recapitulação da tarefa (Parte 1 → Parte 2)

| Etapa                  | Descrição                                                                                               |
|------------------------|---------------------------------------------------------------------------------------------------------|
| Entrada                | Ecocardiogramas CAMUS ( <code>frames/frame_XXXX.png</code> )                                            |
| Rótulos (treino)       | Extraídos das máscaras expert ( <code>masks/mask_XXXX.png</code> ) — pixel predominante 253, 254 ou 255 |
| Inferência (protótipo) | <b>Somente a imagem</b> — a máscara <b>não</b> é usada na predição                                      |
| Splits                 | <code>camus_splits.csv</code> — 630 treino / 135 validação / 135 teste                                  |

Detalhes do pipeline de pré-processamento: `relatorio_fase4_parte1.pdf`.

## 3. Mapeamento das classes — do código à interpretação assistida

As classes técnicas do modelo foram mapeadas para **nomes clínicos compreensíveis**, alinhados às regiões segmentadas no dataset CAMUS (anotações expert de ecocardiografia).

| Classe técnica                              | Pixel na máscara | Nome legível no protótipo                                    | Contexto educacional (simulação)                                                                                                                                      |
|---------------------------------------------|------------------|--------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>estrutur</code><br><code>a_253</code> | 253              | <b>Átrio esquerdo (região predominante)</b>                  | Padrão visual associado à predominância do átrio esquerdo na segmentação; em laudo real o cardiologista avaliaria volume atrial — o modelo <b>não</b> conclui doença. |
| <code>estrutur</code><br><code>a_254</code> | 254              | <b>Cavidade do ventrículo esquerdo (região predominante)</b> | Padrão associado à cavidade do VE; relevante para discussão de volume/função sistólica — o protótipo <b>não</b> calcula fração de ejeção.                             |
| <code>estrutur</code><br><code>a_255</code> | 255              | <b>Miocárdio ventricular (região predominante)</b>           | Padrão associado ao miocárdio; espessura e movimentação parietal seriam analisadas pelo especialista — o modelo <b>não</b> detecta cardiopatia estrutural.            |

**Importante:** este mapeamento traduz a **classificação de região segmentada** para linguagem próxima ao contexto clínico. **Não constitui diagnóstico, não indica normalidade ou patologia e não substitui laudo de ecocardiograma.**

## 4. Modelos implementados

### 4.1 Abordagem A — CNN simples (do zero)

Arquitetura sequencial Keras:

- 3 blocos **Conv2D** ( $32 \rightarrow 64 \rightarrow 128$  filtros) + **MaxPooling**
- **Flatten** → Dropout 0,3 → Dense 128 → Dense (softmax, 3 classes)
- Otimizador: **Adam**
- Loss: **sparsecategoricalcrossentropy**
- Pré-processamento: resize  $224 \times 224$ , RGB, normalização [0, 1]
- **Early stopping** (patience 4, monitor `val_loss`)
- **Class weights** balanceados (classe minoritária `estrutura_253` recebe peso maior)

**Justificativa:** baseline exigida pelo enunciado; permite comparar aprendizado end-to-end no domínio dos ecocardiogramas sem pesos ImageNet.

### 4.2 Abordagem B — Transfer Learning (VGG16)

- Base **VGG16** (`weights='imagenet'`, `include_top=False`), **congelada**
- **GlobalAveragePooling2D** → Dropout 0,3 → Dense 128 → softmax
- Otimizador: Adam (`learning_rate=1e-4`)
- Pré-processamento: `preprocess_input` VGG16 (padrão ImageNet)
- Early stopping (patience 3)

**Justificativa:** VGG16 é modelo trabalhado em aula; features ImageNet aceleram convergência e costumam superar CNN pequena em datasets limitados (~900 imagens).

## 5. Avaliação e métricas

Avaliação no **conjunto de teste** (135 imagens), nunca usadas no treino. Resultados exportados pelo notebook e registrados em `assets/fase4/comparacao_metricas.csv`.

### 5.1 Tabela comparativa (teste)

| Modelo      | Acurácia | Precisão (macro) | Recall (macro) | F1 (macro) |
|-------------|----------|------------------|----------------|------------|
| CNN simples | 71,9%    | 53,7%            | 52,1%          | 52,7%      |
| VGG16 TL    | 51,1%    | 26,8%            | 27,8%          | 27,3%      |

**Conclusão da comparação:** nesta execução, a **CNN simples superou o VGG16** em todas as métricas macro. Isso é plausível em dataset pequeno (~900 imagens) e domínio específico (ecocardiograma em escala de cinza): features ImageNet nem sempre transferem bem sem *fine-tuning* mais agressivo. Ambos os modelos foram treinados e avaliados conforme exige o enunciado; a comparação honesta faz parte da análise crítica do relatório.

O protótipo de upload utiliza o **VGG16** (demonstração do fluxo de inferência); para produção acadêmica ampliada, a **CNN simples** seria a escolha natural com base no teste — ou retreino do VGG16 com descongelamento parcial das camadas.

| Métrica            | Descrição                                      |
|--------------------|------------------------------------------------|
| Acurácia           | Proporção de acertos globais                   |
| Precisão (macro)   | Média das precisões por classe                 |
| Recall (macro)     | Média dos recalls por classe                   |
| F1-score (macro)   | Harmônica entre precisão e recall              |
| Matriz de confusão | Erros entre <code>estrutura_253/254/255</code> |

### 5.2 Evidências visuais ( `assets/fase4/` )

| Arquivo                                      | Conteúdo                              |
|----------------------------------------------|---------------------------------------|
| <code>matriz_confusao_cnn_simples.png</code> | Matriz de confusão — CNN simples      |
| <code>matriz_confusao_vgg16.png</code>       | Matriz de confusão — VGG16            |
| <code>curvas_cnn_simples.png</code>          | Loss e acurácia (treino vs validação) |
| <code>curvas_vgg16.png</code>                | Idem — transfer learning              |
| <code>comparacao_metricas.csv</code>         | Tabela comparativa numérica           |

**Interpretação:** a classe `estrutura_254` (~69% do dataset) domina a acurácia global; a classe `estrutura_253` (~3% dos dados, ~4 exemplos no teste) limita recall/F1 macro — especialmente visível no VGG16 (F1 macro 27,3%).

## 6. Protótipo — Assistente Cardiológico Virtual

### 6.1 Funcionamento

Implementado na última seção do notebook Parte 2:

1. Usuário faz **upload** de um ecocardiograma (PNG)
2. Modelo **VGG16** gera probabilidades por classe (demonstração do fluxo; ver §5.1 — **CNN simples** teve melhor desempenho agregado no teste)
3. Interface exhibe:
  - imagem enviada;
  - gráfico de barras com **nomes legíveis** (átrio / VE / miocárdio);
  - **parecer simulado** em texto;
  - **avisos médicos** em destaque

### 6.2 Exemplo de execução (demonstração)

| Campo          | Valor                                                        |
|----------------|--------------------------------------------------------------|
| Imagem         | <code>frame_0022.png</code>                                  |
| Classe técnica | <code>estrutura_254</code>                                   |
| Nome legível   | <b>Cavidade do ventrículo esquerdo (região predominante)</b> |
| Confiança      | <b>92,8%</b> (alta)                                          |

**Leitura educacional do exemplo:** o modelo associou o frame a um padrão visual compatível com predominância da cavidade do ventrículo esquerdo nas anotações CAMUS. Isso **não** indica diagnóstico de doença nem conduta terapêutica.

### 6.3 Avisos médicos (obrigatórios no protótipo)

O protótipo exhibe, em toda predição:

AVISO IMPORTANTE — PROTÓTIPO ACADÊMICO CARDIOIA

- Isto NÃO é diagnóstico médico nem laudo de ecocardiograma.
- NÃO indica presença ou ausência de doença cardíaca.
- NÃO substitui consulta, exame presencial ou cardiologista.
- Qualquer decisão de saúde exige avaliação de profissional habilitado (médico / cardiologista) com histórico clínico.

Adicionalmente, caixa de alerta para **sintomas de urgência** (dor torácica, falta de ar): orientar **atendimento de emergência**, não o protótipo.

**Recomendação explícita em todo parecer:** “Procure um médico ou cardiologista para interpretação clínica completa do exame, correlação com sintomas e conduta terapêutica, se necessário.”

## 7. Governança, ética e limitações

| Tema                 | Consideração                                                                               |
|----------------------|--------------------------------------------------------------------------------------------|
| LGPD                 | CAMUS anonimizado; em produção real seriam necessários consentimento e controle de acesso. |
| Viés                 | Dataset de um centro; modelo pode não generalizar.                                         |
| Desbalanceamento     | Classe 253 sub-representada; métricas por classe essenciais.                               |
| Simulação vs clínica | Classificação de região ≠ diagnóstico; protótipo é <b>FIAP / educacional</b> .             |
| Responsabilidade     | Decisões clínicas apenas com profissional habilitado.                                      |

## 8. Conclusão (Parte 2)

A Parte 2 cumpre o enunciado da Fase 4:

- **CNN simples** treinada e avaliada no conjunto de teste (**71,9%** de acurácia, **52,7%** F1 macro);
- **Transfer learning (VGG16)** implementado e avaliado (**51,1%** acurácia, **27,3%** F1 macro);
- **Comparação crítica:** CNN simples superou VGG16 neste dataset — resultado documentado honestamente;
- **Métricas** completas com matrizes de confusão e tabela em `assets/fase4/`;

- **Protótipo** interativo (upload) com **interpretação assistida simulada**, nomes clínicos legíveis e **avisos médicos**.

O Assistente Cardiológico Virtual demonstra, de forma técnica e responsável, como visão computacional pode **organizar e interpretar** (de modo simulado) ecocardiogramas, integrando-se ao ecossistema CardioIA iniciado na coleta de imagens CAMUS (Fase 1) e preparando terreno para evoluções futuras (segmentação com máscaras, integração clínica real).

---

## 9. Evidências (checklist da entrega — Parte 2)

---

- ☒ Notebook: `notebooks/fase4_parte2_cnn_classificacao.ipynb`
- ☒ Relatório Parte 2: `docs/relatorio_fase4_parte2.md`
- ☒ CNN simples + VGG16 treinados (modelos em `evidencias_fase4/*.keras` )
- ☒ Prints de métricas e matrizes em `assets/fase4/`
- ☒ Protótipo de upload com parecer simulado e aviso médico `relatorio_fase4_parte1.pdf`