

CardioliA — Fase 5, Parte 1

Assistente Conversacional com NLP: funcionamento do fluxo de diálogo

Projeto: CardioliA — FIAP, 2026 **Integrantes:** Diogo Rebello · Vera Chaves **Disciplina de referência:** PCV — Processamento de Linguagem Natural, Chatbots & Virtual Agents

1. Objetivo e escopo

Esta parte da Fase 5 entrega um assistente conversacional de **atendimento inicial em saúde cardiológica**, modelado no **IBM watsonx Assistant** com *intents*, *entities* e *dialog nodes*, e integrado a um **backend Flask** pela API v2 do serviço.

O assistente orienta, organiza e encaminha — ele **não diagnostica, não prescreve e não ajusta medicação**. Esse limite não é apenas um aviso no rodapé: está codificado no fluxo, como descrito na seção 5.

2. Arquitetura da solução

```
Interface HTML —POST /api/mensagem→ Backend Flask
                                     ↳ watsonx Assistant (NLU + árvore de diálogo)
                                     |   ↳ indisponível? motor local (mesmo skill)
                                     ↳ Conhecimento da Fase 2 (regras + risco)
                                     ↳ SQLite (sessões e mensagens)
```

A integração usa `message_stateless`: o contexto da conversa fica sob guarda da aplicação (memória da sessão + SQLite) em vez de depender de uma sessão da nuvem que expira. Isso simplifica a demonstração e mantém o histórico auditável do nosso lado.

O conteúdo conversacional não é editado à mão no JSON: ele é descrito em Python legível em `app/watson/gerar_skill_json.py`, que gera o arquivo de importação e resolve automaticamente as relações `parent` / `previous_sibling` entre os nós. Uma única fonte de verdade alimenta tanto o Watson quanto o motor local.

3. Modelagem: intenções e entidades

13 intenções, com 116 exemplos de treino no total:

Grupo	Intenções
Sociais	<code>saudacao</code> , <code>agradecimento</code> , <code>despedida</code> , <code>capacidades_assistente</code>

Grupo	Intenções
Clínicas	emergencia_cardiaca , relatar_sintoma , duvida_fator_risco , prevencao_habitos , duvida_exame , duvida_medicamento
Serviço	agendar_consulta , monitoramento_dispositivo , falar_com_humano

8 entidades, 39 valores, cada um com sinônimos coloquiais — porque o paciente diz "meu coração dispara", não "taquicardia":

Entidade	Valores
@sintoma	dor no peito, falta de ar, palpitação, batimentos irregulares, tontura, cansaço, inchaço nas pernas, sudorese, dor no braço, desmaio, aperto na garganta, zumbido no ouvido, febre
@contexto	esforço, repouso, deitado, inclinar o corpo
@característica	irradiação
@intensidade	leve, moderada, forte
@duração	agora, horas, dias, semanas
@fator_risco	hipertensão, colesterol alto, diabetes, tabagismo, obesidade, sedentarismo, histórico familiar
@exame	eletrocardiograma, ecocardiograma, teste ergométrico, Holter, exame de sangue
@turno	manhã, tarde

A entidade @contexto registra **em que situação** o sintoma aparece. Não é um detalhe de conveniência: é exatamente o eixo que os pares do mapa_conhecimento.csv usam para diferenciar **angina estável** (dor ao esforço), **angina instável** (dor em repouso) e **pericardite** (dor ao deitar ou inclinar o corpo).

4. A árvore de diálogo (41 nós)

A ordem dos nós-raiz é a ordem de avaliação no Watson, e ela carrega uma decisão clínica: **emergência vem antes de tudo**.

Boas-vindas → Emergência → Saudação → Capacidades → Triage de sintoma
→ Fatores de risco → Prevenção → Exames → Medicamento → Agendamento
→ Monitoramento → Atendimento humano → Agradecimento → Despedida → Fora de escopo

Triage de sintoma (coleta em quatro campos). Reúne sintoma, situação em que ocorre, duração e intensidade, e devolve um resumo estruturado: o que foi registrado, o que observar nos próximos dias, quando procurar atendimento imediato e o encaminhamento sugerido. O paciente pode responder tudo numa frase só ("falta de ar leve ao subir escadas há dias" preenche os quatro de uma vez) ou aos poucos — só é perguntado o que falta.

A coleta é feita com **nós condicionais e variáveis de contexto**, não com *slots*. A escolha foi medida contra a instância real e está justificada na seção 6: dentro de um nó com slots o Watson consome a fala antes de reavaliar a árvore, e um relato de emergência no meio da triagem era engolido como resposta de uma das perguntas. Com nós comuns, todo turno recomeça pela raiz — onde o nó de emergência é o primeiro.

A estrutura de cada coleta são três peças: um nó de **captura** (`$fluxo == 'triagem'`) que grava o que foi dito e salta para a primeira pergunta pendente; os nós de **pergunta** (`$campo == null`), posicionados depois dos nós temáticos para que uma dúvida seja respondida antes de a pergunta ser repetida; e o nó de **resumo**, que encerra o fluxo.

Fatores de risco e exames. Nós-pai com `skip_user_input` e filhos condicionados ao valor da entidade: `@fator_risco:hipertensao` leva à orientação sobre pressão, `@exame:holter` à explicação do Holter, e um filho `true` responde genericamente quando o assunto veio sem especificação.

Agendamento. Mesma mecânica, com um único campo: o turno de preferência. O protótipo **não pede nome nem contato** — dado pessoal que a simulação não precisa guardar (minimização, seção 8).

5. Tratamento de exceções

Fallback escalonado. O nó `anything_else` incrementa um contador no contexto (`$falhas`) e ramifica em três níveis: pedir reformulação, oferecer o menu de assuntos e, na terceira falha seguida, encaminhar para atendimento humano. O contador é zerado sempre que uma intenção é reconhecida, então falhas isoladas não acumulam.

Digressão. Se o paciente muda de assunto durante uma coleta ("para que serve o Holter?" no meio da triagem), o assistente atende o novo pedido e retoma a coleta no turno seguinte — a variável `$fluxo` continua no contexto. Isso é declarado na condição do nó de captura, que exclui as intenções de digressão (`$fluxo == 'triagem' && !#duvida_exame && ...`). Se a fala apenas não foi compreendida, a pergunta pendente é mantida.

Emergência interrompe qualquer fluxo. A condição do nó combina a intenção com padrões clínicos independentes do classificador:

```
#emergencia_cardiaca
|| @sintoma:desmaio
|| (@sintoma:dor_no_peito && @intensidade:forte)
|| (@sintoma:dor_no_peito && @duracao:agora)
|| (@sintoma:dor_no_peito && @sintoma:sudorese)
|| (@sintoma:dor_no_peito && @sintoma:dor_no_braco)
```

Assim, "dor no peito com suor frio" dispara o alerta mesmo que a classificação de intenção tenha ficado abaixo do limiar. O nó encerra a triagem e orienta SAMU 192.

Limite de escopo clínico. `duvida_medicamento` responde recusando: o assistente declara que não pode orientar dose, troca ou interrupção, dá apenas as orientações seguras (não interromper anti-hipertensivo por conta própria, consultar a bula ou o farmacêutico, levar a lista de medicamentos à consulta) e oferece agendamento.

6. Calibragem do reconhecimento

Dois ajustes vieram de falhas observadas em teste, e valem registro porque ilustram o compromisso entre sensibilidade e especificidade em triagem:

Falso positivo de emergência. "Sinto dor no peito e falta de ar ao subir escadas" — um quadro de angina estável, típico de triagem ambulatorial — era classificado como emergência por semelhança superficial com os exemplos agudos. Corrigimos com exemplos de esforço na intenção `relatar_sintoma` e um limiar de confiança mais alto para a intenção de emergência (0,62 contra 0,38 das demais). A sensibilidade foi preservada pelas condições por entidade acima, que não dependem do classificador.

Reconhecimento de entidades em fala natural. Comparar sinônimos por substring perdia "minhas pernas **estão** inchadas" (palavra intercalada) e "palpitações" (plural irregular em -ão). O módulo `texto_clinico.py` monta, para cada termo, uma expressão regular tolerante a acentuação, plural (inclusive -ão → -ões) e a uma lista fechada de conectores. A mesma função é usada pelo mapa de conhecimento da Fase 2, para que as duas camadas leiam a fala do paciente do mesmo jeito.

Falso negativo de emergência — o achado mais relevante da validação. Ao rodar os 10 relatos de `sintomas_pacientes.txt` contra o assistente, o relato 3 — "*Sinto um aperto **forte** no tórax [...] a sensação irradia para o braço esquerdo*", quadro clássico de síndrome coronariana aguda — **não** disparava o encaminhamento de urgência. A causa: o termo cadastrado é "aperto no tórax", e o casamento tolerava conectores ("estão", "muito") mas não **qualificadores** entre as palavras. Sem reconhecer `@sintoma:dor_no_peito`, a regra dor no peito + irradiação para o braço nunca era avaliada. A correção foi admitir qualificadores de intensidade na lista de palavras intercaláveis. O caso virou teste de regressão: um falso negativo de emergência é a falha mais cara que este assistente pode ter, e não pode voltar despercebido.

6.1 Achados da integração com a instância real

Três comportamentos só apareceram ao rodar contra o watsonx Assistant, e os três mudaram o desenho da solução:

Slots capturam a fala antes de reavaliar a árvore. A primeira versão usava nós do tipo *frame* com *slots*, o recurso natural do Watson para coleta. Em teste, "aperto forte no tórax irradiando para o braço esquerdo" dito no meio da triagem virava resposta da pergunta pendente em vez de disparar a urgência. Habilitar digressão (`digress_out_slots`) e saltar do handler do slot para o nó de emergência não resolveram. A coleta foi reescrita com nós condicionais, e a emergência voltou a interromper qualquer fluxo — comportamento verificado nas duas coletas.

Desambiguação automática atrapalha triagem. Com `disambiguation` ligada, respostas curtas às perguntas da coleta ("leve", "há dias") empataavam intenções por falta de contexto e o Watson devolvia um menu "Qual destes assuntos você quer tratar?" em vez da próxima pergunta. O recurso foi desligado: o tratamento de ambiguidade do Cardiola é o fallback escalonado, que é explícito e auditável.

Ruído era classificado como conversa social. Texto sem sentido ("asdfgh") vinha como `#saudacao` com confiança acima de 0,6, e o fallback nunca rodava. Corrigido com **contraexemplos** (14 exemplos marcados como irrelevantes) e um limiar de confiança explícito nos nós sociais (`#saudacao && intents[0].confidence > 0.5`).

Vale registrar também o que **não** era problema: por várias iterações a resposta parecia vir vazia, e a causa não estava na árvore de diálogo — era a desambiguação devolvendo `response_type: "suggestion"` , que o cliente não sabia interpretar. O cliente passou a tratar esse tipo de resposta, e o diagnóstico correto só veio ao inspecionar o JSON bruto da API em vez da mensagem já formatada.

7. Reaproveitamento das fases anteriores

O reaproveitamento acontece em **duas camadas distintas** — uma no conteúdo do próprio assistente, outra em tempo de execução.

7.1 No vocabulário do assistente (tempo de geração)

O conteúdo conversacional não foi inventado do zero: o gerador do skill **lê os datasets da Fase 2** e os incorpora ao arquivo importado no Watson.

Dataset da Fase 2	Contribuição
<code>mapa_conhecimento.csv</code> (36 termos distintos)	31 termos viram sinônimos de <code>@sintoma</code> , <code>@contexto</code> e <code>@fator_risco</code>
<code>sintomas_pacientes.txt</code> (10 relatos)	9 relatos viram exemplos reais de treino das intenções

Cinco termos ficam de fora **de propósito**, com o motivo declarado no código: `aperto` , `peito` e `tórax` são fragmentos ambíguos já cobertos pelas expressões compostas ("aperto no tórax", "peso no peito"); `pressão` é ambíguo entre pressão arterial e sensação de pressão no peito; e `medo` é um estado emocional — o assistente não faz triagem psíquica.

O décimo relato deixado fora do treino é o de síncope postural. O encaminhamento dele já é garantido pela entidade `@sintoma:desmaio` na condição de emergência; usá-lo como exemplo de `relatar_sintoma` ensinaria o classificador a tratar desmaio ora como urgência, ora como triagem comum.

A ponte entre as duas fases é a tabela `TERMOS_FASE2` no gerador, que precisa dar destino a **todo** termo do CSV. Se a Fase 2 ganhar um sintoma novo, a geração do skill **falha** apontando qual termo ficou sem classificação — as duas camadas não podem divergir em silêncio.

7.2 Na resposta ao paciente (tempo de execução)

Quando a mensagem contém um sintoma, o backend enriquece a resposta com a camada de conhecimento construída na **Fase 2**:

- **Mapa de conhecimento** (`mapa_conhecimento.csv` , 31 pares sintoma → doença): as hipóteses são pontuadas por número de sintomas casados, com a mesma lógica por regras do notebook da Fase 2 — transparente e auditável.
- **Classificador de risco** (`frases_risco.csv` , 303 relatos rotulados): regressão logística sobre TF-IDF, treinada uma vez e mantida em memória.

Ambos aparecem no painel lateral da interface como **apoio à leitura**, nunca como conclusão — o relato "dor no peito ao subir escadas" mostra *Angina estável* com a pontuação e os termos que a justificaram, e o resultado do classificador vem sempre acompanhado da confiança.

8. Governança, ética e limitações

- **Não substitui avaliação médica.** O aviso está na saudação, no rodapé da interface e nas respostas clínicas.
- **Encaminhamento de urgência** explícito (SAMU 192) sempre que houver sinal de gravidade, com a triagem interrompida.
- **Escopo recusado por projeto:** dose, troca e interrupção de medicamento.
- **LGPD:** dados simulados; o SQLite guarda só o texto da conversa, sem CPF, telefone ou identificador de paciente. Credenciais ficam em `.env` , fora do controle de versão.
- **Viés e limitação conhecidos:** o classificador de risco foi treinado com relatos que descrevem valores clínicos (pressão, colesterol, frequência máxima); em falas coloquiais curtas sua confiança cai, e por isso ele é exibido como indício. O reconhecimento de intenções cobre o vocabulário dos 116 exemplos — falas muito fora desse domínio caem, propositalmente, no fallback e no encaminhamento humano.

9. Validação

`app/testar_assistente.py` executa **80 verificações**: emergências reconhecidas, sintomas crônicos que não podem virar alarme, entidades com plural e palavras intercaladas, classificação das 13 intenções, coleta completa por slots (inclusive num único enunciado), digressão, interrupção por emergência, fallback escalonado, recusa de orientação medicamentosa, cobertura do vocabulário derivado da Fase 2, camada de conhecimento e os cinco endpoints da API. Todas passam.

Entre elas estão os **10 relatos reais de sintomas_pacientes.txt** como casos de regressão clínica: cada relato tem o desfecho esperado declarado (encaminhamento de urgência para os relatos 3 e 7, triagem para os demais). São o teste mais próximo do uso real, porque foram escritos na Fase 2 sem nenhuma relação com este assistente.